

## Capítulo VII

### Resultados y discusiones

En este apartado se mostrarán los resultados obtenidos, tras entrenar diferentes modelos de redes neuronales, tanto para las imágenes termográficas como las derivadas topológicas. Los modelos se han escogido según las combinaciones de las técnicas mencionadas en los capítulos 5 y 6, siguiendo estructura que se presenta en la Figura 33.

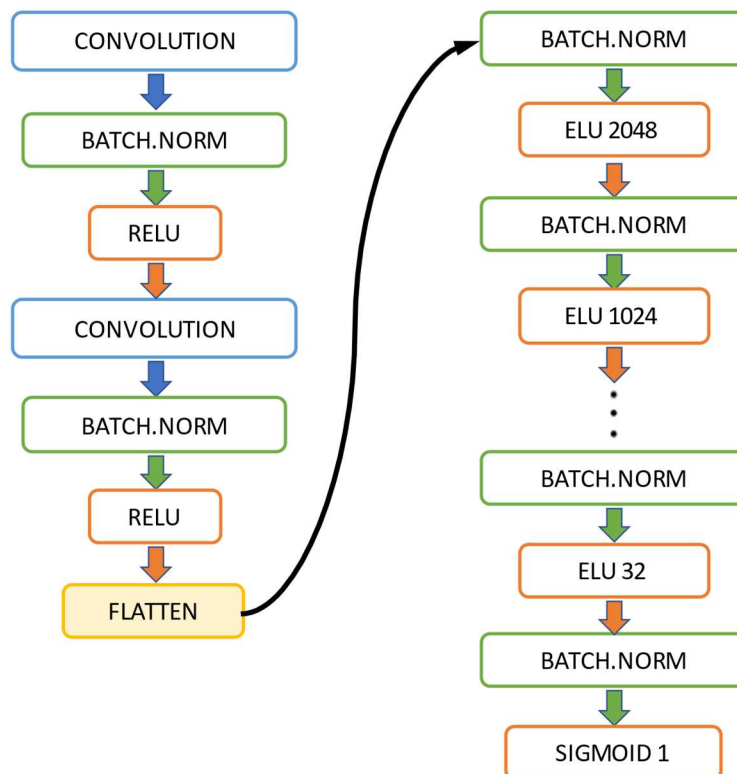


Figura 33: Estructura de la red neuronal convolucional que se ha utilizado en las pruebas.

En la Figura 33, en la columna de la izquierda, podemos ver dos convoluciones con sus respectivos *Batch Normalization* y función de activación. La columna de la izquierda consiste en una red *fully-connected* estructurada de la forma que se indica en la Tabla 2.

## 7.1 Termografías:

Teniendo en cuenta que todas las redes propuestas en este trabajo contienen una red *fully-connected* (segunda columna de la Figura 33), en la Tabla 3 se muestran las diferentes combinaciones que se han propuesto para modelar las redes neuronales dedicadas a las imágenes termográficas.

Modelo	L.R. inicial	k	Momento + Nesterov	Capas convolucionales	max-pooling	Batch	N. de épocas	Error promedio	Tiempo
1	0.01	0				50	50	5.57%	7min
2	0.3	0.5				50	3	5.35%	30seg
3	0.3	0.5	✓			50	3	5.30%	30seg
4	0.5	0.1		✓	✓	50	3	5.15%	90seg
5	0.5	0.1	✓	✓	✓	50	30	4.30%	15min
6	0.5	0.1	✓	✓		50	30	3.87%	33min

Tabla 3: Diferentes modelos de redes neuronales para las termografías.

En los resultados obtenidos de la Tabla 3 se puede apreciar varios detalles:

- El impacto al usar la ratio de aprendizaje exponencial decreciente ha sido muy significativo. Se puede apreciar que el modelo 2, en solamente 3 épocas de entrenamiento, consigue mejores resultados que el modelo 1 usando 50 épocas.
- La aplicación de las capas convolucionales mejora la precisión respecto a los modelos que no las utilizan, aunque se puede apreciar que los tiempos necesarios para el entrenamiento de redes convolucionales es mucho mayor que sin ellas.
- La técnica del descenso acelerado de Nesterov (NAG) junto a un momento con  $\eta = 0.9$ , ha tenido un impacto muy positivo para las redes con capas convolucionales (modelo 5).
- En cuanto al *max-pooling*, pese a ser un método muy eficaz para disminuir el tiempo de entrenamiento, en el modelo 6 se puede apreciar una notable mejora en cuanto a la precisión de la red si eliminamos esta técnica.

Por lo tanto, solamente observando el error promedio obtenido, se puede apreciar que, utilizando un correcto optimizador, una adecuada ratio de aprendizaje y capas convolucionales, se consigue mejorar sustancialmente la precisión del sistema.

Para poder visualizar con más claridad las predicciones obtenidas, en las Figuras 30 al 35, se ha utilizado una media móvil 100 centrada. Esta técnica realiza, para cada punto, una media aritmética con sus 50 valores posteriores y 50 anteriores que se expresa de la siguiente manera:

$$l_i = \frac{1}{n+1} \sum_{j=0}^n p_{(j-\frac{n}{2})+i} \quad (7.1)$$

donde  $l_i$  corresponde a cada uno de los valores de esta media,  $p$  es el punto correspondiente en la serie de datos y  $n$  es en este caso 100. Nótese que la media de cada punto cuenta con 101 valores, puesto que el valor en esa misma posición también se contabiliza. Por lo tanto,  $n$  es siempre un número par, por lo que la media cuenta con un

número impar de valores. En este caso, el valor inicial de esta media tiene que empezar en el punto 51, es decir,  $l_{inicial} = l_{(n/2)+1}$  y el valor final debe acabar 50 puntos antes del valor final de la serie,  $l_{final} = l_{m-(n/2)}$ , siendo  $m$  el número total de valores de la serie. Las medias móviles son herramientas muy utilizadas en diversos campos como el análisis de datos, aprendizaje automático, series temporales, trading en bolsa de valores, etc.... Se ha escogido la media móvil 100, además de por ser una de las más frecuentes a la hora de analizar datos, por tener la capacidad de mostrar claramente cómo fluctúa la media sin perder demasiados matices por la excesiva suavización de esta media, como ocurre con medias móviles de mayor número de valores.

### Termografía: Modelo 1




Figura 34: Resultados obtenidos del primer modelo de red neuronal dedicado a las imágenes termográficas.

### Termografía: Modelo 2




Figura 35: Resultados obtenidos del segundo modelo de red neuronal dedicado a las imágenes termográficas.

### Termografía: Modelo 3

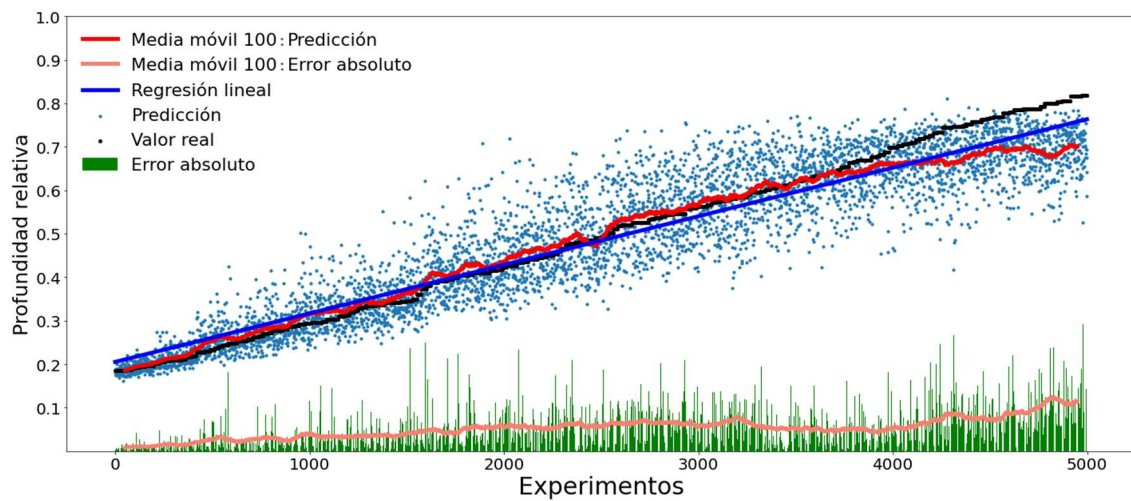


Figura 36: Resultados obtenidos del tercer modelo de red neuronal dedicado a las imágenes termográficas.

### Termografía: Modelo 4

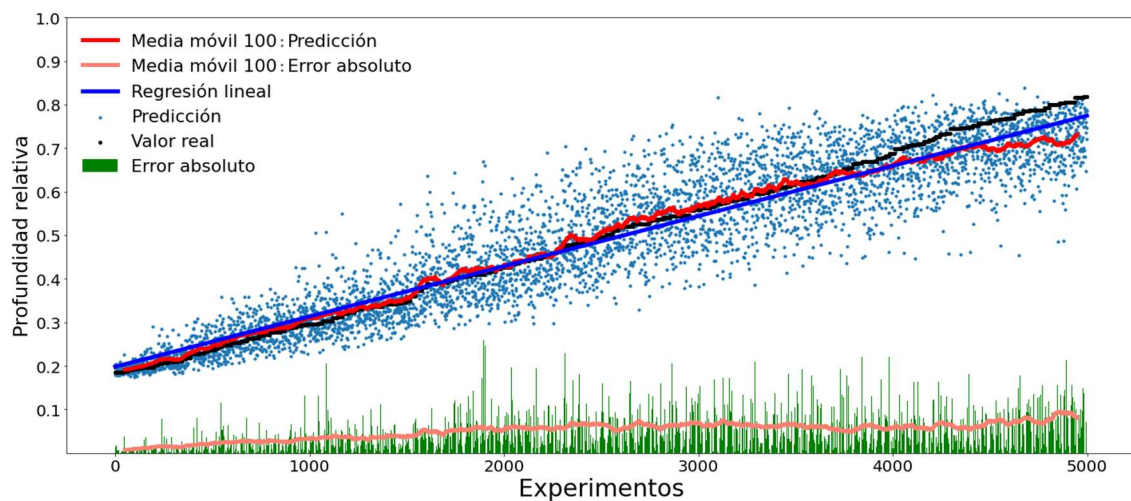


Figura 37: Resultados obtenidos del cuarto modelo de red neuronal dedicado a las imágenes termográficas.

### Termografía: Modelo 5




Figura 38: Resultados obtenidos del quinto modelo de red neuronal dedicado a las imágenes termográficas.



### Termografía: Modelo 6




Figura 39: Resultados obtenidos del sexto modelo de red neuronal dedicado a las imágenes termográficas.

Tras estudiar los resultados obtenidos de los seis modelos (Figura 34 al 39), se puede apreciar los siguientes detalles:

- A medida que mejoran los modelos, la dispersión de las predicciones es considerablemente menor. Éstas se concentran más cerca de los valores reales y se puede visualizar perfectamente si comparamos el Modelo 6 y el Modelo 1.
- La línea roja, que representa una media móvil 100 centrada, nos indica cómo está siendo el promedio de las predicciones respecto a los valores reales (puntos negros). Y se puede apreciar que, en los tres últimos modelos, correspondientes a las redes que utilizan capas convolucionales, esta media se comporta mucho mejor que en los modelos sin dichas capas.

Una de las premisas que se traía de los trabajos anteriores, [1] y [2], es que las redes tienen dificultades a la hora de predecir la posición de los defectos más profundos. Y si nos fijamos en la parte final de las cinco primeras gráficas, nuestra media móvil tiende a alejarse de los valores reales, corroborando esta premisa. Pero si nos fijamos en el Modelo 6, que es nuestro mejor modelo, podemos apreciar que este problema se ha paliado con bastante éxito.

- La línea naranja, que representa una media móvil 100 centrada, nos indica cómo está siendo el promedio de los errores absolutos (barras verdes). Y para visualizar correctamente su comportamiento en los diferentes modelos, se ilustran conjuntamente en la Figura 40:

### Error absoluto T: media móvil 100 centrada

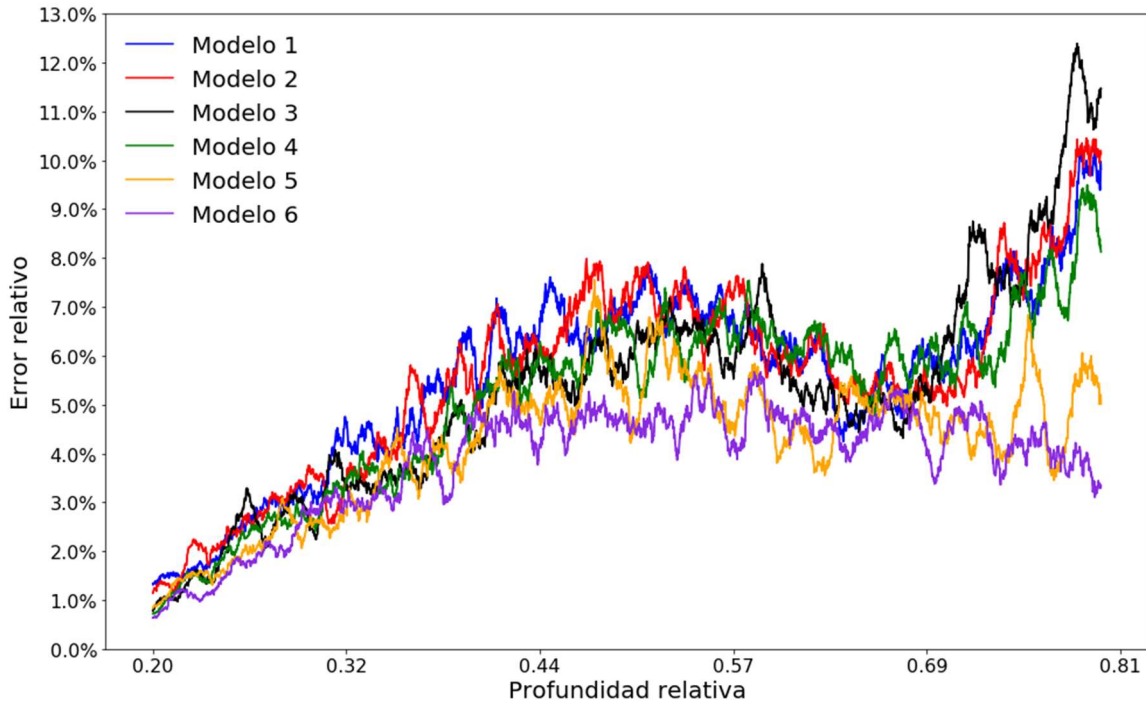


Figura 40: Media móvil centrada de 100 experimentos del error absoluto de los seis modelos de red neuronal para las imágenes termográficas.

En la Figura 40 se aprecia que en general, a mayor profundidad del defecto, los modelos empeoran su precisión. Pero cabe destacar que los Modelos 5 y 6 (líneas morada y amarilla) poseen una precisión notablemente superior, sobre todo a la hora de identificar la posición de los defectos situados a mayor profundidad.

En conclusión, tras estudiar los diferentes modelos de redes neuronales para las termografías, se puede afirmar que las capas convolucionales mejoran notablemente la precisión de las predicciones y pueden solventar el problema del aprendizaje deficitario de los casos en los que los defectos están situados a mayor profundidad.

## 7.2 Derivadas topológicas:

Para procesar la base de datos que contiene derivadas topológicas vamos a utilizar redes del mismo tipo que las consideradas a la hora de procesar termografías (véase el esquema de la Figura 33), por lo tanto, contendrán como base una red *fully-connected* estructurada de la forma que se indica en la Tabla 2. En la Tabla 4 se puede encontrar las diferentes combinaciones que se han propuesto para modelar cada una de las redes que será utilizada para procesar las derivadas topológicas.

Modelo	L.R. inicial	k	Momento + Nesterov	Capas convolucionales	Padding	Max-pooling	Batch	N. de épocas	Error promedio
1	0.01	0					50	20	3.30%
2	0.1	0.3					50	20	2.23%
3	0.1	0.3	✓				50	20	2.07%
4	0.1	0.4	✓	✓		✓	50	20	2.12%
5	0.1	0.4	✓	✓	✓	✓	50	20	2.17%
6	0.1	0.4	✓	✓	✓		50	20	2.15%
7	0.1	0.4	✓	✓			50	20	2.14%

Tabla 4: Diferentes modelos de redes neuronales para las derivadas topológicas.

En los resultados recogidos en la Tabla 4 se puede apreciar varios detalles:

- Al igual que el caso anterior (compárese con la Tabla 3), tanto la ratio de aprendizaje exponencial decreciente como el descenso acelerado de Nesterov mejoran sustancialmente la precisión de los modelos.
- A diferencia de lo observado en el caso de las termografías, cuando los datos corresponden a derivadas topológicas, las capas convolucionales no parecen impactar significativamente en el aprendizaje de la red, puesto que los Modelos 2 y 3, que no utilizan las capas convolucionales, han sido capaces de conseguir una precisión parecida a los que sí tienen dichas capas.
- En un principio, se pensaba que la técnica del *Padding* impactaría positivamente en el entrenamiento y el *Max-Pooling* negativamente, pero se ha visto que todos los modelos con redes convolucionales se han encontrado con un suelo alrededor del 2% de error.

Mirando las Tabla 3 y 4, se puede afirmar que trabajando con derivadas topológicas se obtienen resultados sustancialmente mejores que con termografías. Las técnicas que se han utilizado para mejorar la ratio de aprendizaje y el descenso del gradiente han impactado muy positivamente en los modelos que actúan sobre derivadas topológicas, aunque la adición de capas convolucionales no ha supuesto un impacto significativo como en los modelos con termografías. El motivo puede deberse al tamaño del propio elemento de entrenamiento, ya que, como se comentó con anterioridad, cada elemento es una matriz de tamaño  $10 \times 10$  que contiene los valores de la derivada topológica en una pequeña región que contiene al defecto.

A continuación, en las Figuras 41 a 47 se ilustran gráficamente los resultados obtenidos de los diferentes modelos de las redes de la Tabla 4.

### Derivada topológica: Modelo 1




Figura 41: Resultados obtenidos del primer modelo de red neuronal dedicado a las derivadas topológicas.

### Derivada topológica: Modelo 2

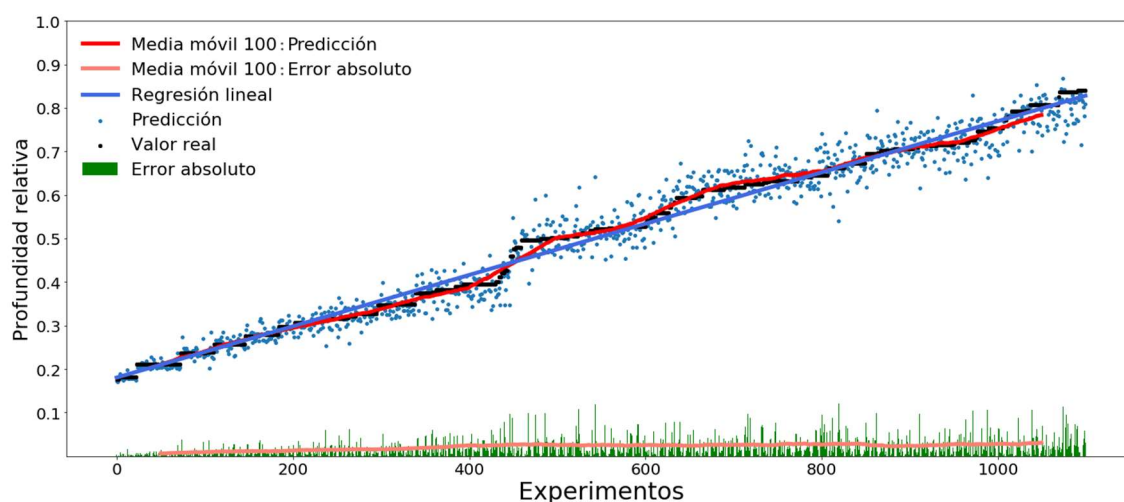


Figura 42: Resultados obtenidos del segundo modelo de red neuronal dedicado a las derivadas topológicas.

### Derivada topológica: Modelo 3




Figura 43: Resultados obtenidos del tercer modelo de red neuronal dedicado a las derivadas topológicas.



### Derivada topológica: Modelo 4




Figura 44: Resultados obtenidos del cuarto modelo de red neuronal dedicado a las derivadas topológicas.

### Derivada topológica: Modelo 5

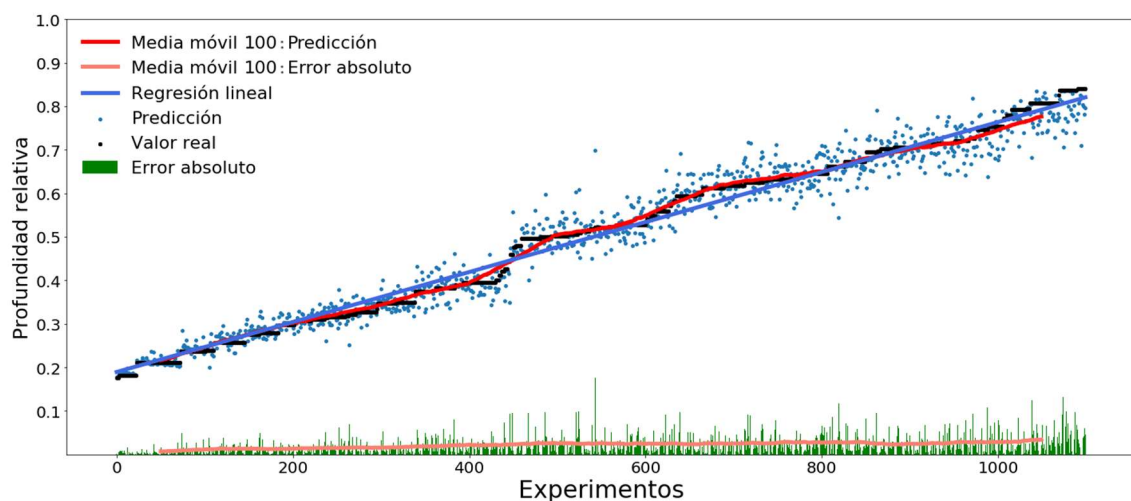


Figura 45: Resultados obtenidos del quinto modelo de red neuronal dedicado a las derivadas topológicas.

### Derivada topológica: Modelo 6




Figura 46: Resultados obtenidos del sexto modelo de red neuronal dedicado a las derivadas topológicas.

### Derivada topológica: Modelo 7




Figura 47: Resultados obtenidos del séptimo modelo de red neuronal dedicado a las derivadas topológicas.

Los resultados obtenidos de los anteriores modelos (Figura 41 a 47), nos permiten apreciar los siguientes detalles:

- La dispersión de las predicciones al trabajar con derivadas topológicas es mucho menor en cualquiera de los modelos que la obtenida al trabajar directamente con las termografías.
- La media móvil 100 centrada (línea roja), nos indica cómo está siendo el promedio de las predicciones respecto a los valores reales (puntos negros). Y se puede apreciar que, en el Modelo 1, esta media se encuentra por debajo de los valores reales en los defectos situados a profundidades pequeñas. Este comportamiento también se encuentra en los modelos de las termografías, pero con los defectos más profundos.
- La línea naranja, que representa una media móvil 100 centrada, nos indica cómo está siendo el promedio de los errores absolutos (barras verdes). Y para visualizar correctamente su comportamiento en los diferentes modelos, se ilustran conjuntamente en la Figura 48:

### Error absoluto DT: media móvil 100 centrada

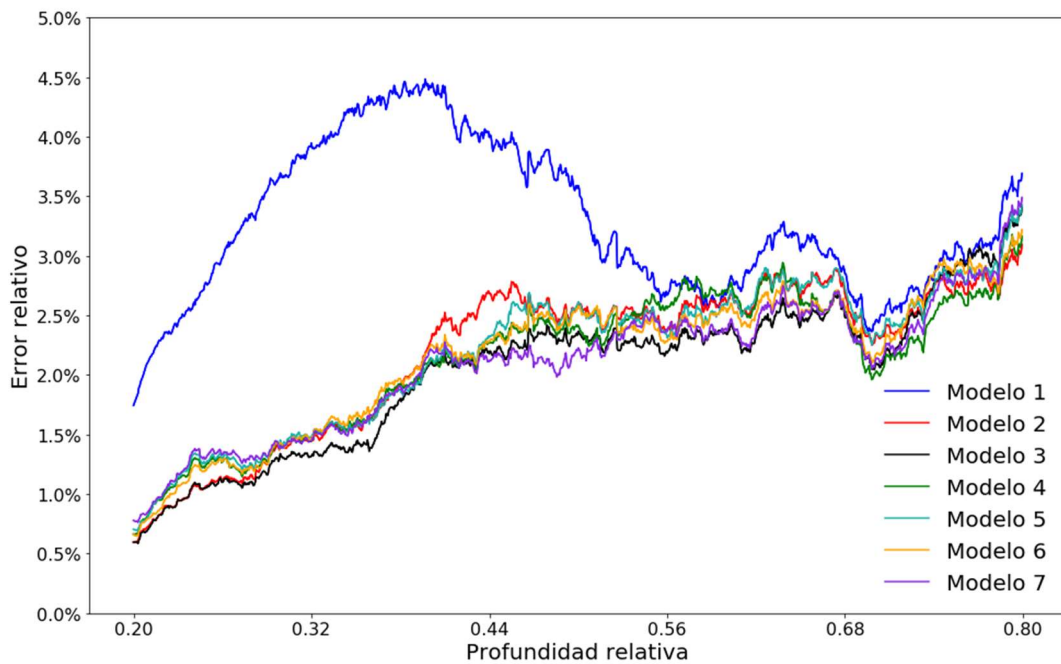


Figura 48: Media móvil centrada de 100 experimentos del error absoluto de los siete modelos de red neuronal para las derivadas topológicas

En vista de los datos recogidos en la Figura 48, se puede afirmar que todos los modelos presentan errores mucho menores a los obtenidos al considerar las termografías sin postprocesar vía la derivada topológica (compárese con la Figura 40). Se puede apreciar que todos los modelos del 2 al 7 empeoran su precisión a medida que la posición del defecto se hace más profunda, aunque el Modelo 1 parece haber tenido dificultades a la hora de aprender los experimentos con defectos a menores profundidades.

En conclusión, los diferentes modelos de redes neuronales para las derivadas topológicas tienen una precisión mucho mayor a los modelos de las termografías. Las capas convolucionales en estos modelos no consiguen una mejora sustancial para el aprendizaje de la red neuronal, aunque las técnicas de la ratio de aprendizaje exponencial decreciente y el descenso acelerado de *Nesterov* sí han contribuido significativamente a mejorar el entrenamiento de la red, solventando el problema del aprendizaje deficitario en los casos en los que los defectos están situados a menor profundidad (Modelo 1).

Como resumen final, hay que destacar que los resultados obtenidos provienen de termografías con apreciable ruido donde era muy complicado detectar el lugar de los fallos. Con las derivadas topológicas era posible situar los defectos en altura, pero no se obtenía la información sobre su profundidad. A partir de los resultados que se obtuvieron de las redes neuronales utilizadas en los trabajos de Sergio Colubi [1] y Ángel Mateo [2], se observó que los modelos de redes con derivadas topológicas salían muy beneficiados respecto a los modelos con termográficas. Con las mejoras implementadas en este TFG: las capas convolucionales, la ratio de aprendizaje exponencial decreciente, el descenso

acelerado de *Nesterov*, el *Batch Normalization*, la estructura convergente de la red neuronal, etc., en nuestros mejores modelos, gracias a estas técnicas, se ha conseguido unos resultados con errores medios por debajo del 4% para los modelos con termografías y sobre el 2% para los modelos con derivadas topológicas, todo ello con entrenamientos de menos de 50 épocas.

En el trabajo de Sergio Colubi [1], en una de las redes neuronales que construye, en concreto la red 13.1 (su red neuronal más efectiva), se realiza un entrenamiento de 1000 épocas red simple *fully-connected* consiguiendo unos resultados muy precisos. Esta red consigue un error medido en error cuadrático medio de  $4.7899 \cdot 10^{-4}$ .

Para comparar la efectividad de nuestras redes, se ha realizado un entrenamiento con la misma base de datos usada por Sergio, con una red neuronal que tiene la configuración del Modelo 6 de la Tabla 4, y se ha visto que consigue llegar al mínimo en únicamente 20 épocas. Los errores resultantes son los mostrados en la Tabla 5.

Error cuadrático medio	$4.2051 \cdot 10^{-4}$
Error absoluto medio	1.48 %

Tabla 5: Resultados obtenidos con el modelo 6 de red neuronal aplicado a la base de datos utilizada por Sergio en la red 13.1 del trabajo [1].

Por lo tanto, se puede apreciar una pequeña mejora alrededor del 12%, aunque el punto a destacar es el hecho de haber conseguido una precisión superior, con un número de épocas de entrenamiento 50 veces inferior. En la Figura 49, se compara los resultados obtenidos con el Modelo 6 respecto a la red 11.3 del trabajo de Sergio. Y como comentamos anteriormente solo hay una mejora alrededor del 12%, por lo que es difícil apreciarlo gráficamente.




Figura 49: Comparativa entre resultados de la red 13.1 del trabajo de Sergio [1] (izquierda), y los obtenidos con el modelo 6 de red neuronal aplicadas a la misma base de datos (derecha).